Identificação temporal de estados operacionais

Projeto 2 — Modelo Markoviano Oculto

Portfólio de Inteligência Artificial 1

Resumo. Um HMM discreto identifica estados industriais não observáveis a partir de padrões discretizados de sensores. Foram implementados Forward escalonado, Viterbi em logaritmos e Baum–Welch para estimação de parâmetros.

1 Problema e modelagem

Os estados ocultos são normal, sobrecarga, desgaste, pré-falha e falha crítica. Cada instante emite um de seis símbolos que representam combinações de vibração, temperatura e consumo. A matriz de transição é persistente: estados vizinhos são mais prováveis e a falha crítica é absorvente em 86%. Essa hipótese representa degradação gradual, mas permite recuperação parcial.

2 Métodos

Com $A_{ij} = P(S_t = j \mid S_{t-1} = i)$, $B_{jk} = P(O_t = k \mid S_t = j)$ e $\pi_i = P(S_1 = i)$, o Forward usa

$$\alpha_t(j) = B_{j,o_t} \sum_i \alpha_{t-1}(i) A_{ij}.$$

Após cada passo, α_t é dividido por sua soma; a log-verossimilhança é a soma dos logaritmos desses fatores. O Viterbi maximiza a mesma recorrência no domínio log e guarda retroponteiros. Baum–Welch alterna responsabilidades γ e ξ para atualizar A, B e π por EM, sem depender de biblioteca de HMM.

3 Experimentos e resultados

Uma sequência de 180 instantes foi gerada com semente 19 a partir do próprio modelo. O Viterbi obteve acurácia $0,856$ e F1 macro $0,740$. A matriz de confusão foi

$$\begin{pmatrix} 41 & 2 & 0 & 0 & 0 \\ 5 & 29 & 2 & 0 & 0 \\ 1 & 7 & 2 & 3 & 0 \\ 0 & 0 & 1 & 21 & 4 \\ 0 & 0 & 0 & 1 & 61 \end{pmatrix}.$$

Em oito sequências adicionais de 100 símbolos, Baum–Welch aumentou a log-verossimilhança de $-1179,383$ para

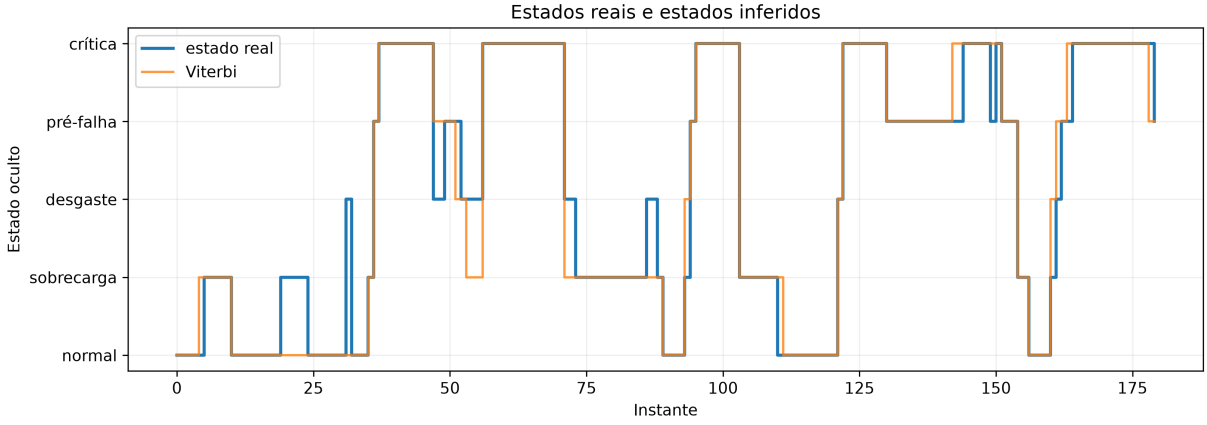


Figura 1: Estados reais e estimados.

$-1160,193$ em 40 iterações. Os erros concentram-se em estados vizinhos, especialmente desgaste, comportamento esperado quando as emissões se sobrepõem.

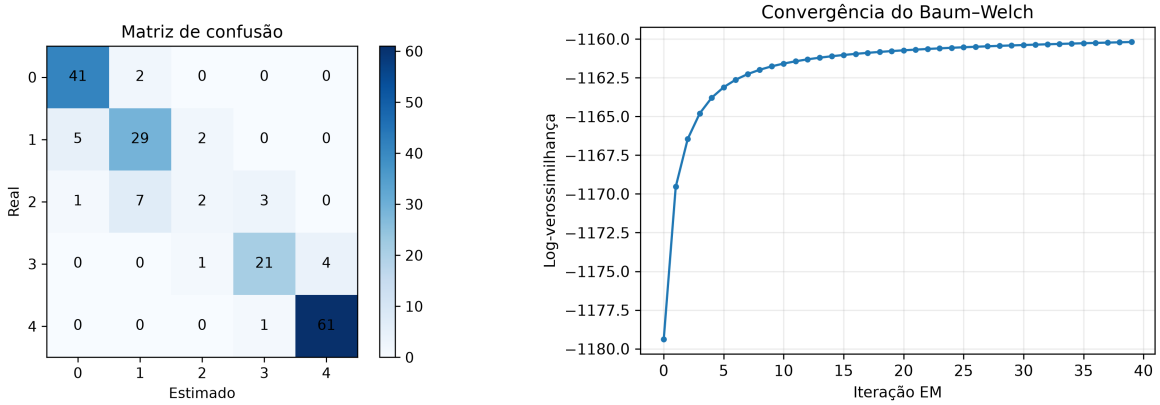


Figura 2: Confusão e convergência do Baum–Welch.

4 Conclusão

O HMM recupera a dinâmica latente e produz alarmes temporais menos sensíveis a uma medição isolada. A identificação depende de separação das emissões e da hipótese de Markov de primeira ordem; mudanças abruptas, estados não modelados e parâmetros mal calibrados podem causar confusão. O escalonamento evita underflow em sequências longas. Referências: Rabiner (1989); Baum et al. (1970).