Estimação de movimento com sensores ruidosos

Projeto 3 — Filtro de Kalman

Portfólio de Inteligência Artificial 1

Resumo. Este projeto estima posição e velocidade de um componente mecânico usando medições de posição contaminadas por ruído. O filtro linear manual inclui covariância do erro e a forma de Joseph, além de uma análise de especificação incorreta de R.

1 Problema e modelo

O estado é $\mathbf{x}_k = [p_k, v_k]^T$, com passo $\Delta t = 0,5$ s e dinâmica quase uniforme:

$$\mathbf{x}_k = F\mathbf{x}_{k-1} + \mathbf{w}_k, \quad F = \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix}, \quad z_k = H\mathbf{x}_k + v_k, \; H = [1\ 0].$$

O processo usa $Q = \mathrm{diag}(0,01; 0,01)$ e a medição nominal usa $R = 4$. A trajetória sintética tem posição inicial 0, velocidade 1,2 e perturbação gaussiana de processo.

2 Algoritmo

Predição: $\hat{x}_{k|k-1} = F\hat{x}_{k-1|k-1}$ e $P_k^- = FP_{k-1}F^T + Q$. Na atualização, $S = HP^-H^T + R$, $K = P^-H^TS^{-1}$ e $\hat{x}_k = \hat{x}^- + K(z - H\hat{x}^-)$. A covariância usa a forma de Joseph:

$$P_k = (I - KH)P^-(I - KH)^T + KRK^T,$$

que preserva simetria e positividade melhor sob arredondamento.

3 Experimentos e resultados

Com semente 23 e 120 amostras, o erro bruto de posição foi RMSE 1,954 e MAE 1,544; após filtragem, RMSE 1,176 e MAE 0,973. Portanto, o ganho foi obtido sem observar diretamente a velocidade.

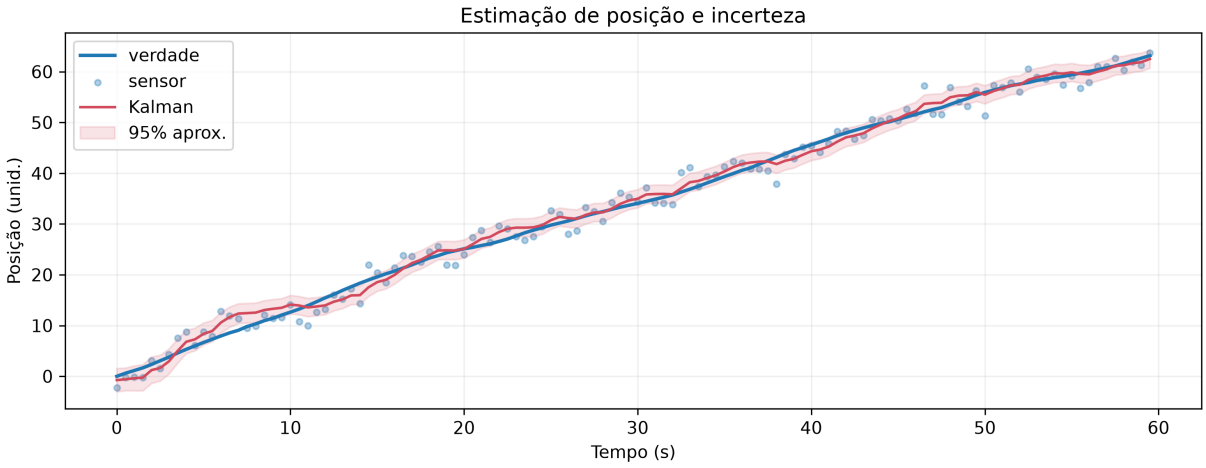


Figura 1: Trajetória, sensor, estimativa e intervalo aproximado de 95%.

R	0,25	1	4	16
RMSE sensor	0,489	0,977	1,954	3,909
RMSE Kalman	0,379	0,689	1,176	1,902

Quando o filtro assume $R = 0,25$ embora o sensor tenha variância 4, o RMSE sobe para 1,386: confiar excessivamente em medições ruins torna a estimativa mais instável.

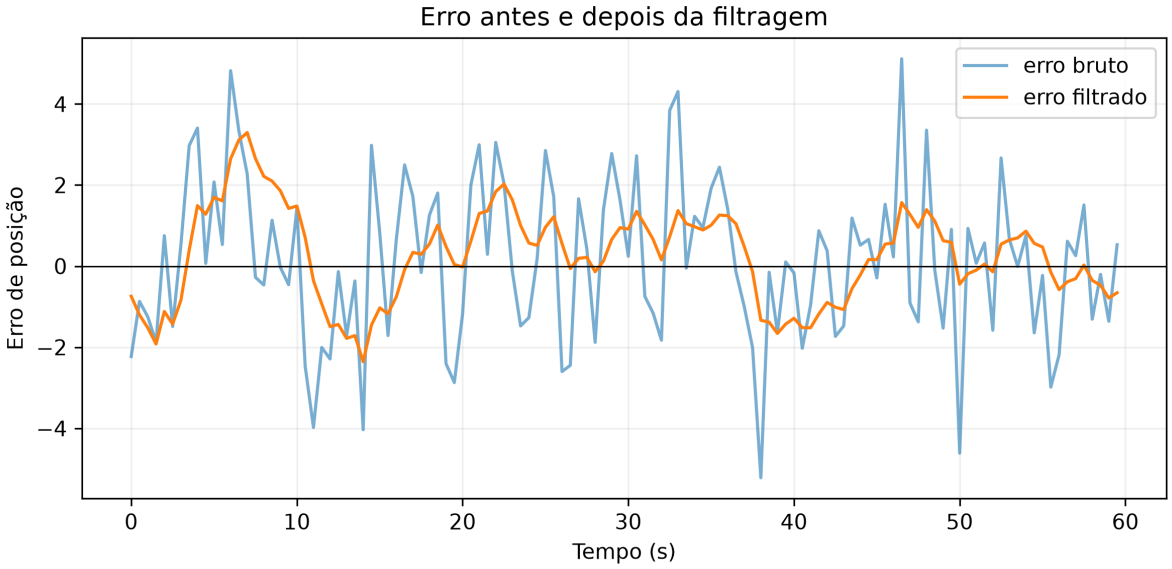


Figura 2: Erro de posição antes e depois do filtro.

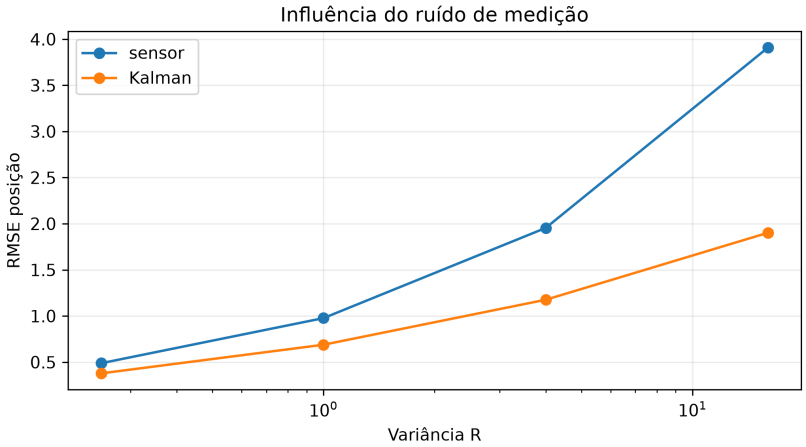


Figura 3: Ruído maior aumenta ambos os erros, mas o filtro mantém vantagem.

4 Conclusão

O Kalman é adequado quando a dinâmica é aproximadamente linear e os ruídos têm covariâncias conhecidas. Ele suaviza sensores sem simplesmente aplicar média móvel, pois incorpora previsão física e incerteza. Modelos não lineares, ruídos não gaussianos e falhas de sensor exigem EKF/UKF, filtros robustos ou detecção de outliers. Referências: Kalman (1960); Simon (2006).