Tratando Incerteza em Monitoramento Inteligente

Portfólio de Inteligência Artificial

Aluno: Lucas Andrade Zanetti
Matrícula: 241039645
Disciplina: Inteligência Artificial
Código: FGA0221
Professor: Fabiano Araujo Soares

4 de novembro de 2026

Resumo

Este relatório apresenta um portfólio integrado sobre tratamento de incerteza aplicado ao monitoramento de uma máquina industrial sujeita a ruído, variações operacionais e falhas. Foram desenvolvidos três projetos independentes em Python: uma Rede Bayesiana para diagnóstico probabilístico, um Modelo Markoviano Oculto (HMM) para identificação de estados operacionais ao longo do tempo e um Filtro de Kalman para estimação de variáveis físicas. As implementações centrais foram desenvolvidas manualmente, com validações, testes automatizados, dados sintéticos reproduzíveis e visualizações em alta resolução. Os resultados mostram que cada técnica responde a uma dimensão distinta do problema: relações causais e evidências, dinâmica temporal de estados ocultos e estimação contínua sob ruído.

Sumário

1 Introdução e proposta **3**
1.1 Objetivos . . . 3

2 Arquitetura e metodologia comum **3**
2.1 Critérios de avaliação . . . 3

3 Projeto 1 — Rede Bayesiana **3**
3.1 Modelagem do problema . . . 3
3.2 Inferência . . . 4
3.3 Resultados . . . 4

4 Projeto 2 — Modelo Markoviano Oculto **5**
4.1 Modelagem temporal . . . 5
4.2 Resultados . . . 5

5 Projeto 3 — Filtro de Kalman **6**
5.1 Modelo dinâmico . . . 6
5.2 Filtragem . . . 7
5.3 Resultados . . . 7

6 Discussão comparativa **8**

7 Validação, reprodutibilidade e limitações **8**

8 Conclusão **9**

1 Introdução e proposta

Sistemas industriais modernos combinam sensores heterogêneos e decisões que precisam ser tomadas mesmo quando as medições são incompletas ou imprecisas. Temperatura, vibração, pressão e consumo energético não revelam diretamente o estado interno de uma máquina: são observações sujeitas a ruído e podem ser compatíveis com mais de uma causa. O objetivo deste portfólio é demonstrar, em um mesmo cenário, três formas complementares de representar e tratar essa incerteza.

O tema central é **monitoramento inteligente e diagnóstico de falhas em sistemas industriais**. A máquina considerada possui componentes sujeitos a desgaste, condições de sobrecarga e degradação da lubrificação. Os sintomas observados pelos sensores podem indicar falha mecânica ou elétrica, mas não determinam uma conclusão por si só. O portfólio foi organizado para responder a três perguntas:

1. Dadas evidências atuais, qual é a probabilidade de cada falha? (Rede Bayesiana.)
2. Qual foi a sequência mais provável de estados operacionais que produziu as observações? (HMM.)
3. Qual é a posição e a velocidade mais prováveis de um componente quando o sensor é ruidoso? (Kalman.)

1.1 Objetivos

O objetivo geral é implementar e avaliar algoritmos probabilísticos capazes de apoiar manutenção preditiva. Os objetivos específicos são: (i) representar dependências causais por um grafo acíclico e realizar inferência exata; (ii) inferir estados ocultos em uma sequência temporal e estimar parâmetros por Baum–Welch; (iii) combinar modelo dinâmico e medições para obter uma estimativa filtrada; e (iv) avaliar limitações, sensibilidade e estabilidade numérica.

2 Arquitetura e metodologia comum

Os três projetos estão separados em diretórios, mas seguem uma metodologia comum. Os algoritmos principais estão em módulos próprios, os experimentos em arquivos separados e cada projeto possui uma entrada `main.py`. Os dados são sintéticos, pois permitem controlar as condições verdadeiras e medir o desempenho contra um gabarito conhecido. Todas as execuções relevantes usam sementes fixas: 19 no HMM e 23 no Kalman.

As figuras são produzidas com Matplotlib a 300 DPI. As métricas são salvas em arquivos JSON em `results/metrics.json`, o que evita transcrever resultados manualmente. Os testes automatizados verificam propriedades matemáticas centrais, incluindo normalização do Forward, validade de probabilidades, respeito a transições impossíveis, simetria da covariância e rejeição de dimensões incompatíveis.

2.1 Critérios de avaliação

No diagnóstico Bayesiano, foram comparadas probabilidades posteriores em quatro cenários e calculada uma variação de sensibilidade. No HMM, foram usadas acurácia, F1 macro, matriz de confusão e evolução da log-verossimilhança. No Kalman, foram usados RMSE e MAE da posição, além de uma comparação entre níveis de ruído e de uma hipótese incorreta para a covariância de medição.

3 Projeto 1 — Rede Bayesiana

3.1 Modelagem do problema

A rede possui oito variáveis binárias: desgaste (*wear*), lubrificação insuficiente, sobrecarga, temperatura alta, vibração alta, pressão inadequada, falha mecânica e falha elétrica. Desgaste influencia a lubrificação;

sobrecarga e lubrificação influenciam temperatura e pressão; desgaste e sobrecarga influenciam vibração. Os sintomas, por sua vez, contribuem para as hipóteses de falha.

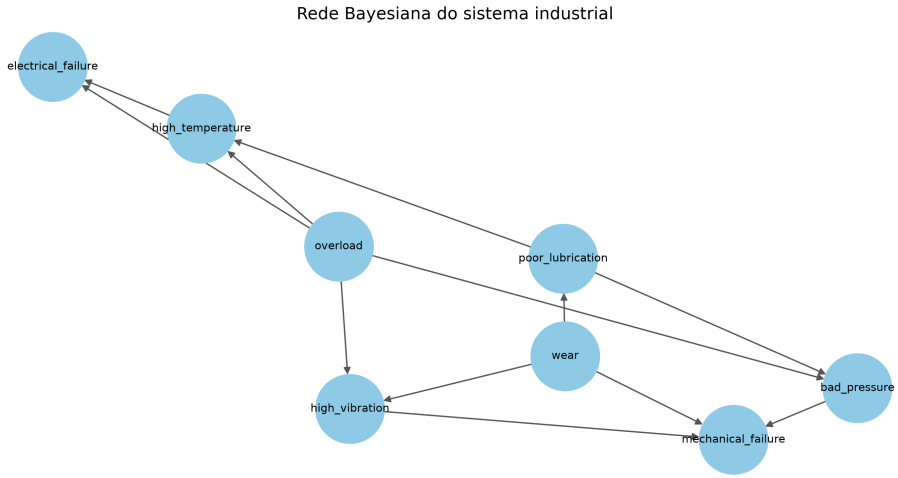


Figura 1: Grafo acíclico direcionado da Rede Bayesiana.

Para uma atribuição completa $\mathbf{x}$, a distribuição conjunta é fatorada como

$$P(\mathbf{x}) = \prod_i P(x_i \mid \text{pais}(X_i)).$$

As probabilidades condicionais foram definidas manualmente para refletir o conhecimento do cenário: por exemplo, a probabilidade de vibração alta aumenta com desgaste e sobrecarga. O código verifica a existência de todos os nós, ausência de ciclos, completude das CPTs e validade das probabilidades.

3.2 Inferência

Para uma consulta Q e evidência $\mathbf{e}$, foi implementada enumeração exata:

$$P(Q \mid \mathbf{e}) = \frac{\sum_{\mathbf{y}} P(Q, \mathbf{e}, \mathbf{y})}{\sum_{q,\mathbf{y}} P(q, \mathbf{e}, \mathbf{y})}.$$

Essa escolha é didática e adequada à rede pequena. Ela expõe diretamente a fatoração e o cálculo da distribuição posterior, sem ocultar o mecanismo em uma biblioteca pronta. Sua limitação é o crescimento exponencial com o número de variáveis.

3.3 Resultados

Tabela 1: Probabilidades posteriores produzidas pela execução.

Cenário	Falha mecânica	Falha elétrica	Desgaste	Sobrecarga
Operação normal	0,147	0,068	0,180	0,150
Temperatura e vibração altas	0,628	0,445	0,552	0,715
Indícios elétricos	0,036	0,308	0,159	0,346
Múltiplas evidências	0,824	0,472	0,625	0,789

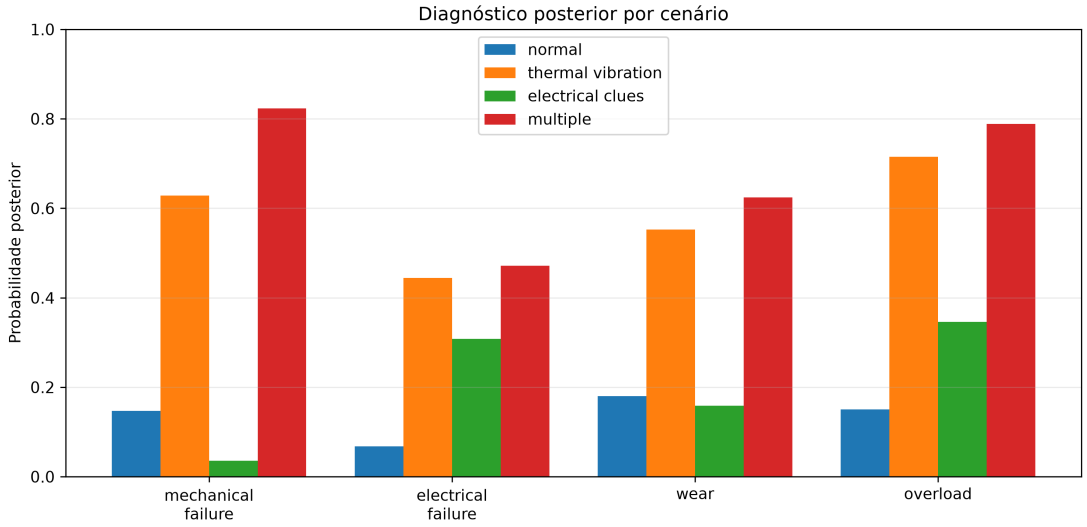


Figura 2: Comparação das probabilidades posteriores nos cenários avaliados.

No cenário normal, a falha mecânica apresenta probabilidade posterior de 0,147. Com temperatura e vibração altas, ela sobe para 0,628. Com múltiplas evidências, chega a 0,824. A análise de sensibilidade mostrou que, mantendo temperatura alta, acrescentar vibração alta elevou a probabilidade de falha mecânica em 0,5235. Já o cenário com indícios elétricos, temperatura alta e pressão/vibração normais, favoreceu a hipótese elétrica (0,308) e reduziu a mecânica (0,036), demonstrando que evidências negativas também são informativas.

4 Projeto 2 — Modelo Markoviano Oculto

4.1 Modelagem temporal

O HMM considera cinco estados ocultos: normal, sobrecarga, desgaste, pré-falha e falha crítica. As observações são seis símbolos discretos que representam combinações de vibração, temperatura e consumo energético. A matriz de transição é persistente e favorece estados próximos, representando degradação gradual. A emissão de cada estado possui um perfil próprio, mas com sobreposição para representar sensores imperfeitos.

Se $A_{ij} = P(S_t = j \mid S_{t-1} = i)$, $B_{jk} = P(O_t = k \mid S_t = j)$ e $\pi_i = P(S_1 = i)$, o algoritmo Forward usa

$$\alpha_t(j) = B_{j,o_t} \sum_i \alpha_{t-1}(i) A_{ij}.$$

Para evitar underflow, cada vetor α_t é escalonado pela própria soma; a log-verossimilhança é obtida somando os logaritmos dos fatores de escala. O Viterbi foi implementado em logaritmos e conserva probabilidades zero como transições impossíveis. O Baum–Welch usa as responsabilidades γ e ξ para atualizar A, B e π por máxima verossimilhança iterativa.

4.2 Resultados

Uma sequência de 180 instantes foi gerada com semente 19 a partir do modelo conhecido. A sequência estimada pelo Viterbi obteve acurácia de **0,856** e F1 macro de **0,740**. A maior parte das confusões ocorreu entre estados vizinhos, principalmente desgaste, sobrecarga e pré-falha, o que é coerente com emissões parcialmente sobrepostas.

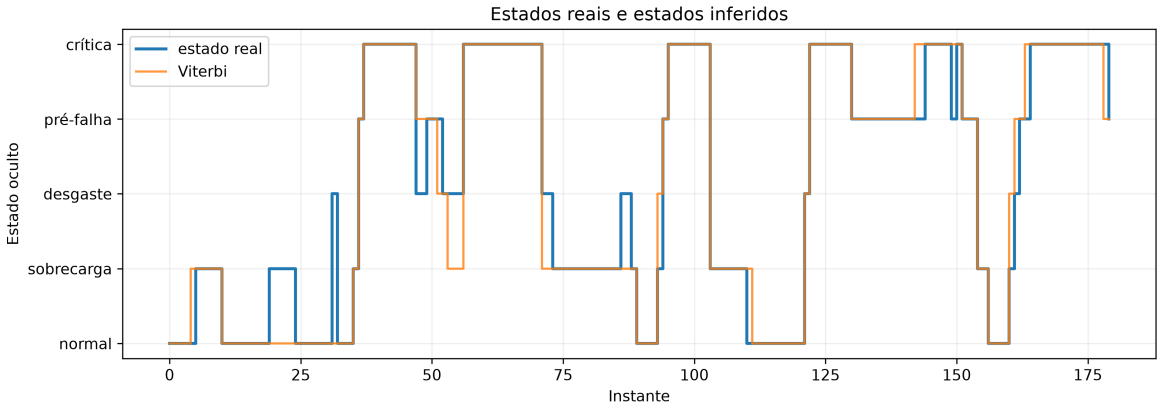


Figura 3: Estados reais e estados estimados pelo Viterbi.

Tabela 2: Matriz de confusão: linhas são estados reais e colunas são estados estimados.

	Normal	Sobrecarga	Desgaste	Pré-falha	Crítica
Normal	41	2	0	0	0
Sobrecarga	5	29	2	0	0
Desgaste	1	7	2	3	0
Pré-falha	0	0	1	21	4
Crítica	0	0	0	1	61

Em oito sequências adicionais de 100 símbolos, o Baum–Welch aumentou a log-verossimilhança de $-1179,383$ para $-1160,193$ em 40 iterações. Esse aumento indica melhora do ajuste aos dados, embora não garanta que os estados aprendidos mantenham a mesma interpretação sem uma etapa de identificação dos rótulos.

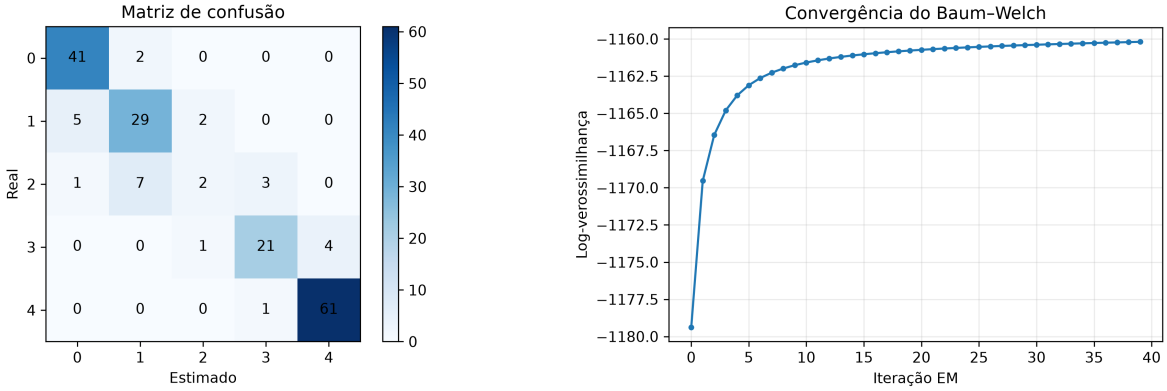


Figura 4: Matriz de confusão e convergência do Baum–Welch.

5 Projeto 3 — Filtro de Kalman

5.1 Modelo dinâmico

O estado físico é $\mathbf{x}_k = [p_k, v_k]^T$, contendo posição e velocidade. Com $\Delta t = 0,5$ s, o modelo quase uniforme é

$$\mathbf{x}_k = F\mathbf{x}_{k-1} + \mathbf{w}_k, \quad F = \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix}, \qquad z_k = H\mathbf{x}_k + v_k, \quad H = [1\ 0].$$

O processo usa $Q = \mathrm{diag}(0,002; 0,01)$ e a medição nominal usa $R = 4$. A trajetória foi simulada com posição inicial zero, velocidade inicial 1,2 e perturbação gaussiana de processo.

5.2 Filtragem

Na predição:

$$\hat{x}_{k|k-1} = F\hat{x}_{k-1|k-1}, \qquad P_k^- = FP_{k-1}F^T + Q.$$

Na atualização:

$$S_k = HP_k^-H^T + R, \qquad K_k = P_k^-H^TS_k^{-1},$$

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k(z_k - H\hat{x}_{k|k-1}).$$

Para melhorar a estabilidade numérica, a covariância é atualizada na forma de Joseph:

$$P_k = (I - K_kH)P_k^-(I - K_kH)^T + K_kRK_k^T.$$

Na implementação, o ganho é calculado por solução de sistema linear, evitando a inversão explícita de S_k.

5.3 Resultados

Com semente 23 e 120 amostras, o sensor apresentou RMSE de posição 1,954 e MAE 1,544. Após a filtragem, os valores caíram para RMSE 1,176 e MAE 0,973.

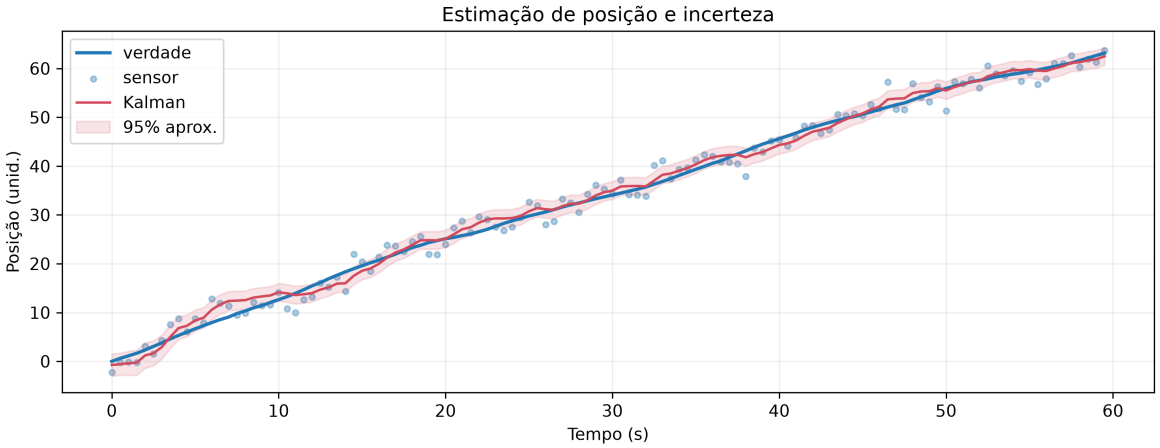


Figura 5: Trajetória verdadeira, medições, estimativa e incerteza aproximada.

Tabela 3: Influência da variância real do ruído de medição.

Variância R	0,25	1	4	16
RMSE do sensor	0,489	0,977	1,954	3,909
RMSE do Kalman	0,379	0,689	1,176	1,902

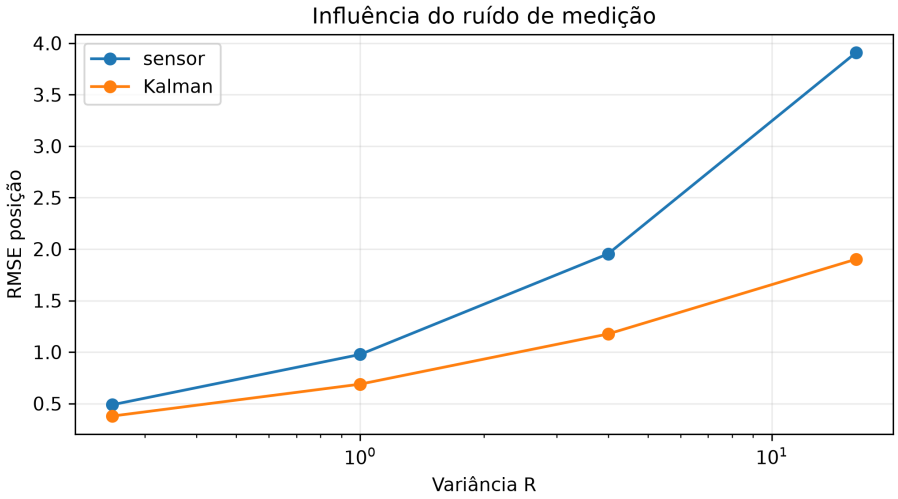


Figura 6: Comparação do erro em diferentes níveis de ruído.

O filtro manteve vantagem em todos os níveis testados. Quando o ruído verdadeiro tinha variância 4, mas o filtro assumiu incorretamente $R = 0,25$, o RMSE foi 1,386, maior que o valor nominal 1,176. Isso mostra que a qualidade depende não apenas do algoritmo, mas também da calibração das covariâncias.

6 Discussão comparativa

Os três métodos não são concorrentes diretos; eles modelam incertezas diferentes. A Rede Bayesiana é apropriada para diagnóstico causal e integração de evidências em um instante. O HMM representa dependência temporal discreta e permite reconstruir uma trajetória de estados ocultos. O Kalman é adequado para variáveis contínuas em sistemas dinâmicos aproximadamente lineares, produzindo também uma covariância de incerteza.

Tabela 4: Síntese das contribuições e limitações.

Método	Principal contribuição	Limitação observada
Rede Bayesiana	Inferência explicável de causas e falhas a partir de evidências	Enumeração cresce exponencialmente; CPTs dependem de conhecimento/calibração
HMM	Identificação de estados ocultos e evolução temporal	Depende do conjunto de estados e da separação das emissões
Kalman	Estimação contínua suavizada com incerteza explícita	Pressupõe dinâmica linear e ruídos adequadamente modelados

Uma arquitetura industrial realista poderia combinar os três resultados: o Kalman filtraria sinais contínuos, o HMM transformaria sequências em estados operacionais e a Rede Bayesiana integraria o estado atual com evidências causais para priorizar falhas e ações de manutenção. Essa composição deve ser feita com cuidado para evitar contar duas vezes a mesma evidência.

7 Validação, reprodutibilidade e limitações

Os códigos foram executados após as alterações finais e os testes automatizados passaram com 7 casos. Foram verificadas: sintaxe dos módulos, normalização das matrizes do HMM após Baum–Welch, simetria e semidefinição positiva das covariâncias do Kalman, completude das CPTs e geração dos

arquivos de métricas e figuras. Os três relatórios auxiliares individuais permanecem no repositório, mas este documento é o relatório geral principal.

As conclusões são limitadas pelo uso de dados sintéticos e por parâmetros especificados manualmente. Os resultados não substituem validação em dados históricos de sensores, registros de manutenção e diferentes regimes de operação. Em continuidade, seria importante estimar CPTs e emissões a partir de dados reais, testar HMMs com estados não estacionários, usar filtros robustos contra outliers e comparar a enumeração com eliminação de variáveis em redes maiores.

8 Conclusão

O portfólio demonstrou três perspectivas complementares para tratar incerteza em sistemas industriais. A Rede Bayesiana quantificou diagnósticos e respondeu de forma sensível a evidências combinadas. O HMM recuperou estados ocultos com acurácia de 0,856 e mostrou aumento da verossimilhança durante o aprendizado. O Filtro de Kalman reduziu substancialmente os erros de posição e evidenciou o impacto de uma hipótese incorreta sobre o ruído.

Mais importante que os valores isolados, os experimentos evidenciam as hipóteses de cada algoritmo. A escolha do método deve acompanhar a natureza da incerteza: dependências causais, evolução temporal discreta ou dinâmica contínua. O código, os resultados e as figuras foram organizados para permitir reprodução e inspeção dos cálculos.

Referências

1. BAUM, L. E. et al. A maximization technique occurring in the statistical analysis of probabilistic functions of Markov chains. *The Annals of Mathematical Statistics*, v. 41, n. 1, p. 164–171, 1970. DOI: 10.1214/aoms/1177697196.

2. KALMAN, R. E. A new approach to linear filtering and prediction problems. *Journal of Basic Engineering*, v. 82, n. 1, p. 35–45, 1960. DOI: 10.1115/1.3662552.

3. KOLLER, D.; FRIEDMAN, N. *Probabilistic Graphical Models: Principles and Techniques*. MIT Press, 2009.

4. RABINER, L. R. A tutorial on hidden Markov models and selected applications in speech recognition. *Proceedings of the IEEE*, v. 77, n. 2, p. 257–286, 1989. DOI: 10.1109/5.18626.

5. RUSSELL, S.; NORVIG, P. *Artificial Intelligence: A Modern Approach*. 4. ed. Pearson, 2021.

6. SIMON, D. *Optimal State Estimation: Kalman, H Infinity, and Nonlinear Approaches*. Wiley, 2006.